

ΣΤΑΤΙΣΤΙΚΕΣ ΜΕΘΟΔΟΙ ΜΗΧΑΝΙΚΗΣ ΜΑΘΗΣΗΣ

ΑΛΕΞΑΚΗ ΒΑΣΙΛΙΚΗ Α.Μ :1097464

ΕΡΓΑΣΙΑ 1: Πρόβλεψη Τιμών Μετοχών με Γραμμική Παλινδρόμηση

Πρόβλεψη Τιμής Μετοχής AMGN - Amgen Inc.

Στόχος της εργασίας είναι η πρόβλεψη της μηνιαίας τιμής κλεισίματος της μετοχής **AMGN** της εταιρείας **Amgen Inc.**, με γραμμική και πολυωνυμική παλινδρόμηση, καθώς και με μεθόδους μείωσης διάστασης. Τα μοντέλα αξιολογήθηκαν τόσο με βραχυπρόθεσμη όσο και μακροπρόθεσμη πρόβλεψη ώστε να διερευνηθεί η δυνατότητα γενίκευσης του μοντέλου στον χρόνο.

1. ΣΥΛΛΟΓΗ ΔΕΔΟΜΕΝΩΝ - monthly_data.py

Τα δεδομένα ανακτήθηκαν από το **API** της **Alpha Vantage** και αφορούν ιστορικές τιμές μετοχής σε **ημερήσια** και **μηνιαία** συχνότητα. Αρχικά έγινε λήψη των ημερήσιων δεδομένων της μετοχής **AMGN** και στη συνέχεια πραγματοποιήθηκε μετατροπή της συχνότητας από ημερήσια σε μηνιαία, ώστε η ανάλυση να πραγματοποιηθεί σε μεγαλύτερη χρονική κλίμακα και να μειωθεί ο θόρυβος της χρονοσειράς. Παράλληλα, ανακτήθηκαν απευθείας και τα **μηνιαία** δεδομένα από το **API**. Τα τελικά αυτά δεδομένα **ταξινομήθηκαν χρονικά** και αποθηκεύτηκαν στο αρχείο **AMGN_monthly.csv**, το οποίο χρησιμοποιήθηκε ως είσοδος σε όλα τα επόμενα στάδια της ανάλυσης.

Για κάθε μήνα καταγράφηκαν οι παρακάτω μεταβλητές: **open**: τιμή ανοίγματος, **high**: μέγιστη τιμή, **low**: ελάχιστη τιμή, **close**: τιμή κλεισίματος και **volume**: όγκος συναλλαγών.

2. ΠΡΟΕΠΕΞΕΡΓΑΣΙΑ ΔΕΔΟΜΕΝΩΝ – preprocessing.py

Στο αρχείο **preprocessing.py** πραγματοποιήθηκε προεπεξεργασία των δεδομένων για τη βελτίωση της ποιότητάς τους και την κατάλληλη προετοιμασία τους για εκπαίδευση μοντέλων μηχανικής μάθησης.

Αρχικά, εφαρμόστηκε **φίλτρο Gaussian** με παράμετρο $\sigma = 1$ στην τιμή κλεισίματος, με στόχο τη μείωση του θορύβου και των τυχαίων διακυμάνσεων στη χρονοσειρά.

Στη συνέχεια, δημιουργήθηκαν χαρακτηριστικά καθυστέρησης - **lag features** ώστε να ενσωματωθεί **χρονική πληροφορία** στα δεδομένα. Επιλέχθηκε αριθμός καθυστερήσεων **N = 3**, μετά από πειραματισμούς με μεγαλύτερες τιμές, οι οποίες δεν οδήγησαν σε ουσιαστική βελτίωση των αποτελεσμάτων. Για κάθε μήνα δημιουργήθηκαν τα εξής χαρακτηριστικά:

close_t-1, close_t-2, close_t-3 και **volume_t-1, volume_t-2, volume_t-3**

Με τον τρόπο αυτό, κάθε δείγμα περιλάμβανε πληροφορία για τους **τρεις προηγούμενους μήνες**.

Ο **διαχωρισμός των δεδομένων** πραγματοποιήθηκε χρονικά ως εξής:

Σύνολο εκπαίδευσης - **Training set** : Έτη πριν το 2024 (**train.csv**)

Σύνολο επικύρωσης - **Validation set** : Έτη 2024–2025 (**validation.csv**)

Για την **αξιολόγηση της απόδοσης** των μοντέλων χρησιμοποιήθηκαν οι μετρικές σφάλματος **MAE** (Mean Absolute Error) και **RMSE** (Root Mean Squared Error). Οι συγκεκριμένες μετρικές επιλέχθηκαν ώστε να παρέχουν πλήρη εικόνα τόσο για το μέσο σφάλμα πρόβλεψης όσο και για την επίδραση μεγάλων αποκλίσεων.

3. ΕΡΩΤΗΜΑ Α : Γραμμική Παλινδρόμηση - **A_linearModel.py**

Για τη μοντελοποίηση χρησιμοποιήθηκε γραμμικό μοντέλο παλινδρόμησης με είσοδο τα χαρακτηριστικά καθυστέρησης τριών μηνών ($N = 3$), τόσο για την τιμή κλεισίματος όσο και για τον όγκο συναλλαγών.

Αξιολόγηση

```
TRAINING
MAE: 1.1577931620425572
RMSE: 1.6484090444218102
```

```
VALIDATION
MAE: 2.654208319604572
RMSE: 3.440099041011889
```

Συντελεστές μοντέλου:

```
open      -4.626442e-01
high      -4.814080e-02
low       -3.748803e-02
volume    -1.930024e-09
close_t-1  2.746712e+00
volume_t-1 -1.587841e-09
close_t-2  -1.710502e+00
volume_t-2 -2.658072e-10
close_t-3  5.126273e-01
volume_t-3 1.923492e-10
dtype: float64
```

Η απόδοση του μοντέλου αξιολογήθηκε στο σύνολο εκπαίδευσης και στο σύνολο επικύρωσης χρησιμοποιώντας τις μετρικές **MAE** και **RMSE**.

Τα αποτελέσματα δείχνουν μικρό σφάλμα στο σύνολο εκπαίδευσης και ελαφρώς αυξημένο στο σύνολο επικύρωσης, αναμενόμενο για χρονοσειρές, δεν υποδηλώνει σημαντικό overfitting.

Από την **ανάλυση των συντελεστών** προκύπτει ότι οι **προηγούμενες τιμές κλεισίματος close_t-3 και close_t-1** έχουν τη **μεγαλύτερη επιρροή** στην πρόβλεψη της τρέχουσας τιμής, καθώς σε αυτές αντιστοιχούν οι μεγαλύτεροι θετικοί συντελεστές. **Αντίθετα**, οι συντελεστές που σχετίζονται με τον **όγκο συναλλαγών** είναι κατά πολύ μικρότεροι σε μέγεθος. Επομένως, ο όγκος διαδραματίζει **σημαντικά μικρότερο ρόλο** στην πρόβλεψη σε σύγκριση με την ιστορική τιμή **κλεισίματος**.

Τέλος, οι τιμές **ανοίγματος, υψηλού και χαμηλού** (open, high, low) εμφανίζουν μικρή αρνητική συνεισφορά. Έτσι, φαίνεται να έχουν **περιορισμένη προγνωστική τους ισχύ** σε σχέση με τις τιμές κλεισίματος των προηγούμενων χρονικών περιόδων.

Επιπλέον εφαρμόστηκαν δύο στρατηγικές αξιολόγησης - **linear_AB.py**

- **Μέθοδος A:** Πρόβλεψη του επόμενου μήνα με χρήση των πραγματικών δεδομένων.
- **Μέθοδος B:** Μακροπρόθεσμη πρόβλεψη - Recursive forecasting, όπου κάθε πρόβλεψη χρησιμοποιείται ως είσοδος για την επόμενη χρονική στιγμή.

```
LINEAR MODEL RESULTS
METHOD A MAE: 6.909
METHOD B MAE: 20.749
Reliable horizon (MAE ≤ 10): 1 months
```

Η **μέθοδος A** παρουσιάζει σημαντικά μικρότερο σφάλμα σε σύγκριση με τη **μέθοδο B**, γεγονός που δείχνει ότι το **γραμμικό μοντέλο** είναι αρκετά αποτελεσματικό για βραχυπρόθεσμη πρόβλεψη, όταν χρησιμοποιούνται πραγματικές τιμές προηγούμενων μηνών.

Αντίθετα, στη **μέθοδο B** παρατηρείται σημαντική αύξηση του σφάλματος, καθώς τα λάθη των προηγούμενων προβλέψεων συσσωρεύονται και επηρεάζουν τις μελλοντικές εκτιμήσεις. Έτσι, ο **αξιόπιστος χρονικός ορίζοντας** περιορίζεται στον **ένα μήνα** είναι φανερό η δυσκολία της μακροπρόθεσμης πρόβλεψης χρηματιστηριακών δεδομένων με απλό γραμμικό μοντέλο.

Εικόνα 1

actual	predicted
314.26	308.5125224176855
273.83	294.13491204694293
284.32	275.1739021098272
273.94	268.4210881531962
305.85	308.9276543417389
312.45	312.8812341178103
332.47	330.5675222879897
333.83	315.67967786291007
322.21	319.9842549881776
320.16	316.6080798420599
282.87	279.9832766594532
260.64	258.4538872182057
285.42	276.90553334223796
308.06	308.74900037938164
311.55	324.3672919414701
290.92	279.0410328729643
288.18	269.3562043024895
279.21	282.6023941761946
295.1	301.5555247787395
287.71	288.6508052053842
282.2	272.706244318387
298.43	296.86126810053
345.46	329.85932670711395
337.49	336.98273803187993

Εικόνα 2

horizon	actual	predicted	abs_error
1	314.26	308.51252241768555	5.7474775823144455
2	273.83	310.2858293807366	36.45582938073659
3	284.32	309.69029208418874	25.370292084188748
4	273.94	310.4839749872879	36.543974987287925
5	305.85	310.72508562733293	4.875085627332908
6	312.45	310.6590931797895	1.7909068202104663
7	332.47	310.66966726524976	21.80033273475027
8	333.83	310.6886428332033	23.141357166796695
9	322.21	310.68690128300824	11.52309871699174
10	320.16	310.68559298419495	9.47440701580507
11	282.87	310.68651767345625	27.816517673456246
12	260.64	310.68666105496675	50.04666105496676
13	285.42	310.6865358469329	25.266535846932868
14	308.06	310.68655361770703	2.6265536177070317
15	311.55	310.68657367805844	0.8634263219415743
16	290.92	310.6865685152509	19.766568515250867
17	288.18	310.6865670327976	22.50656703279759
18	279.21	310.68656827952617	31.47656827952619
19	295.1	310.68656830872186	15.586568308721837
20	287.71	310.6865681327951	22.976568132795137
21	282.2	310.68656816977085	28.486568169770862
22	298.43	310.6865681909213	12.256568190921314
23	345.46	310.68656818174185	34.77343181825813
24	337.49	310.68656818060634	26.803431819393666

Εικόνα 3

horizon	mae
1	5.7474775823144455
2	21.101653481525517
3	22.524533015746595
4	26.029393508631927
5	21.79853193237212
6	18.463927747011848
7	18.940557030974478
8	19.465657047952256
9	18.58315056673442
10	17.672276211641485
11	18.594479980897372
12	21.215495070403154
13	21.52711359167467
14	20.177073593534125
15	18.88949710876129
16	18.944314071666888
17	19.153858363498106
18	19.838453358833
19	19.61466993514294
20	19.782764845025547
21	20.19723167001342
22	19.83629242096378
23	20.447037612150492

Εικόνα 1: Σύγκριση πραγματικών και προβλεπόμενων μηνιαίων τιμών κλεισίματος για τη μέθοδο A. Κάθε γραμμή αντιστοιχεί σε έναν μήνα του συνόλου επικύρωσης. Παρατηρείται ότι

οι προβλέψεις βρίσκονται κοντά στις πραγματικές τιμές, γεγονός που επιβεβαιώνει την ικανοποιητική απόδοση του γραμμικού μοντέλου σε βραχυπρόθεσμη πρόβλεψη.

Εικόνα 2: Αποτελέσματα της μεθόδου B με αναδρομική πρόβλεψη. Εκτυπώνονται οι πραγματικές τιμές, οι προβλεπόμενες τιμές, ο χρονικός ορίζοντας πρόβλεψης -horizon και το απόλυτο σφάλμα ανά μήνα. Παρατηρείται ότι το σφάλμα αυξάνεται σημαντικά καθώς αυξάνεται ο χρονικός ορίζοντας, ένδειξη συσσώρευσης λάθους στη μακροπρόθεσμη πρόβλεψη.

Εικόνα 3: Μεταβολή της μέσης απόλυτης απόκλισης MAE σε συνάρτηση με τον χρονικό ορίζοντα πρόβλεψης - horizon. Παρατηρείται απότομη αύξηση του σφάλματος ήδη από τον δεύτερο μήνα, γεγονός που δείχνει ότι το γραμμικό μοντέλο είναι αξιόπιστο μόνο για βραχυπρόθεσμες προβλέψεις.

4. ΕΡΩΤΗΜΑ Β: Πολυωνυμικό Μοντέλο με L1 και L2 Κανονικοποίηση - B_polynomialModel.py

Για τη μοντελοποίηση των μη γραμμικών σχέσεων μεταξύ των χαρακτηριστικών εφαρμόστηκε πολυωνυμικός μετασχηματισμός δεύτερου βαθμού, αυξάνοντας τον αριθμό των χαρακτηριστικών.

Ως εισόδοι χρησιμοποιήθηκαν καθυστερημένες τιμές των μεταβλητών **close** και **volume**. Αρχικά δημιουργήθηκαν **10 χαρακτηριστικά**, τα οποία μετά την πολυωνυμική επέκταση αυξήθηκαν σε **65 χαρακτηριστικά** μέσω συνδυασμών δεύτερου βαθμού.

Στη συνέχεια εκπαιδεύτηκαν δύο πολυωνυμικά μοντέλα:

Ridge Regression (L2 regularization): η οποία περιορίζει το μέγεθος των συντελεστών και μειώνει τη μεταβλητότητα του μοντέλου και **Lasso Regression** (L1 regularization): η οποία επιπλέον μηδενίζει ορισμένους συντελεστές, κάνοντας ταυτόχρονα και feature selection.

Τα μοντέλα εκπαιδεύτηκαν με τις ίδιες εισόδους με το γραμμικό μοντέλο, για άμεση σύγκριση.

Οι υπερπαράμετροι των μοντέλων επιλέχθηκαν έπειτα από πειραματισμούς:

Για την **Lasso** δοκιμάστηκαν τιμές [0.001, 0.01, 0.05, 0.1, 0.5] και επιλέχθηκε **$\alpha = 0.05$** , καθώς παρείχε την καλύτερη ισορροπία μεταξύ σφάλματος εκπαίδευσης και επικύρωσης.

Για την Ridge δοκιμάστηκαν τιμές [0.1, 1, 10, 50, 100] και επιλέχθηκε **$\alpha = 10$** , που έδωσε το μικρότερο **MAE** και **RMSE** στο σύνολο επικύρωσης χωρίς έντονο overfitting.

* Κατά την εκπαίδευση των γραμμικών μοντέλων εμφανίστηκαν αριθμητικές αστάθειες λόγω διαφορετικής κλίμακας χαρακτηριστικών και ισχυρής συσχέτισης μεταξύ τους. Έτσι, πριν την εκπαίδευση, για την αποφυγή overfitting, εφαρμόστηκε κανονικοποίηση: **StandardScaler**, ώστε όλα τα χαρακτηριστικά να βρίσκονται στην ίδια κλίμακα.

```
linear_model\coordinate_descent.py:695: ConvergenceWarning: Objective did not converge. You might want to increase the number of iterations, check the scale of the features or consider increasing regularisation. Duality gap: 2.618e+03, tolerance: 1.458e+02
  model = cd_fast.enet_coordinate_descent(
C:\Users\vassi\AppData\Local\Packages\PythonSoftwareFoundation.Python.3.11_qbz5n2kfra8p0\LocalCache\local-packages\Python311\site-packages\sklearn\linear_model\ridge.py:215: LinAlgWarning: Ill-conditioned matrix (rcond=3.03626e-17): result may not be accurate.
  return linalg.solve(A, xy, assume_a="pos", overwrite_a=True).T
```

Αξιολόγηση

```
Feature Count
Original features: 10
Polynomial features: 65
```

POLYNOMIAL MODEL RESULTS

METHOD A

```
LASSO MAE: 8.22
RIDGE MAE: 9.96
LASSO RMSE: 10.43
RIDGE RMSE: 12.72
```

METHOD B

```
LASSO MAE: 19.51
RIDGE MAE: 21.01
LASSO RMSE: 22.58
RIDGE RMSE: 24.59
```

Reliable Horizon (MAE ≤ 10)

```
LASSO: 1
RIDGE: 1
```

Από την αξιολόγηση προκύπτει ότι το μοντέλο **Lasso**

υποδεικνύει καλύτερη γενίκευση στα δεδομένα επικύρωσης, έναντι της **Ridge**. Η διαφορά αυτή οφείλεται στην ικανότητα της **Lasso** να πραγματοποιεί ταυτόχρονα επιλογή χαρακτηριστικών, μηδενίζοντας τους μη σημαντικούς πολυωνυμικούς όρους και περιορίζοντας την πολυπλοκότητα και αποφεύγοντας έτσι το **overfitting**.

Και εδώ εφαρμόστηκαν οι δύο στρατηγικές αξιολόγησης :

- **Μέθοδος A:** Πρόβλεψη του επόμενου μήνα με χρήση των πραγματικών δεδομένων του validation set.

Το μοντέλο **Lasso** παρουσίασε μικρότερο σφάλμα και στις δύο μετρικές, γεγονός που υποδεικνύει καλύτερη γενίκευση.

- **Μέθοδος B:** Μακροπρόθεσμη πρόβλεψη - Recursive forecasting, όπου κάθε πρόβλεψη χρησιμοποιείται ως είσοδος

για την επόμενη χρονική στιγμή.

Παρατηρείται σημαντική αύξηση του σφάλματος και για τα δύο μοντέλα λόγω της συσσώρευσης σφάλματος.

Εικόνα 1 - Προβλέψεις με πραγματικά δεδομένα

```
actual,predicted_lasso,predicted_ridge
314.26,307.0474699696042,309.280582571962
273.83,290.96823103992125,307.47336799960385
284.32,273.46765203740205,283.7606864237581
273.94,266.4998180362544,280.16677116587266
305.85,305.29567958491816,311.6465393953687
312.45,311.56217174896386,322.8852083798565
332.47,328.12864619958555,337.24958659446673
333.83,314.2860739971027,335.2791115303979
322.21,317.37902805981633,334.1838223758422
320.16,313.7960966635462,328.0946290544931
282.87,273.82961282503055,299.4517187597084
260.64,255.21806366118864,273.2894698638565
285.42,273.1518081321062,284.41399977430297
308.06,306.80065486945136,320.69968984054395
311.55,323.471722523287,337.8430538565123
290.92,276.57714792374554,298.4419080367919
288.18,266.60011559015004,284.14256538445176
279.21,279.81382398806653,295.1400260731615
295.1,298.76205022797905,307.0549663310308
287.71,288.46962953124165,299.38743373007503
282.2,271.95390290398865,281.3877254299323
298.43,294.73470835360285,299.44418968004607
345.46,325.32507162870314,331.48979745668436
337.49,340.58545996870424,352.54696356846125
```

Εικόνα 2 - MAE ανά χρονικό ορίζοντα

```
horizon,mae_lasso,mae_ridge
1,7.212530030395726,4.979417428038005
2,19.49189877535457,20.227672581348685
3,19.582405247198494,22.041906135981247
4,22.335382941837892,26.038748563359817
5,18.10654539745085,22.03543524161654
6,16.398762617800525,18.46644976102897
7,18.03960357258242,18.749876917569605
8,19.439144052281748,19.13402124012277
9,19.236636609016728,18.14329093033343
10,18.86972352062454,17.143812584888423
11,19.129084984550204,18.23442377490504
12,21.197726202894227,20.995568354842888
13,21.041958376587584,21.425913068788358
14,19.78662277791187,20.17763605004529
15,18.931331610448478,18.863107495492727
16,18.602669922070334,19.002281701375498
17,18.473850753871467,19.286259596739086
18,18.857678164940054,20.037015431169984
19,18.36478690378054,19.87242949764181
20,18.290684767861674,20.0938022969992
21,18.48602093044058,20.55647268936688
22,17.92587198744495,20.239354940641444
23,18.923323458226402,20.813735912677526
24,19.50557063978859,21.008168494135592
```

Εικόνα 3 - Αναδρομική πρόβλεψη

```
horizon,actual,predicted_lasso,predicted_ridge,abs_error_lasso,abs_error_ridge
1,314.26,307.04746996960426,309.280582571962,7.212530030395726,4.979417428038005
2,273.83,305.6012675203134,309.30592773465935,31.771267520313415,35.475927734659365
3,284.32,304.08341819088633,309.99037324524636,19.76341819088634,25.670373245246367
4,273.94,304.5343160257561,311.96927584549553,30.594316025756086,38.02927584549553
5,305.85,304.65880478009734,311.87218195464345,1.1911952199026814,6.022181954643429
6,312.45,304.5901512804511,311.8284776419089,7.859848719548893,0.6215223580911129
7,332.47,304.58535069872624,312.0195601431866,27.884649301273782,20.450439856813432
8,333.83,304.59407258982293,312.00696850200507,29.235927410177055,21.82303149799492
9,322.21,304.5934229371034,311.9925515479813,17.616577062896567,10.217448452018687
10,320.16,304.59249427490516,312.01149252411665,15.567505725094861,8.148507475883378
11,282.87,304.5926996238068,312.0105356750712,21.722699623806818,29.14053567507119
12,260.64,304.59277960467847,312.0081587341592,43.95277960467848,51.36815873415924
13,285.42,304.5927444609079,312.010049636134,19.172744460907893,26.590049636133983
14,308.06,304.59274000487244,312.0100348063854,3.467259995127563,3.9500348063854176
15,311.55,304.592744734039,312.00970773175686,6.95725526596101,0.45970773175685054
16,290.92,304.5927445963982,312.0098947896171,13.67274459639816,21.089894789617063
17,288.18,304.59274406268963,312.00990592255647,16.412744062689626,23.829905922556463
18,279.21,304.592744153106,312.00986461649524,25.382744153106046,32.799864616495256
19,295.1,304.5927442029093,312.0098826941347,9.49274420290925,16.909882694134694
20,287.71,304.5927441854032,312.0098854847896,16.882744185403226,24.299885484789627
21,282.2,304.59274418201875,312.0098805367205,22.39274418201876,29.809880536720527
22,298.43,304.5927441845367,312.00988221740727,6.1627441845366775,13.57988221740726
23,345.46,304.59274418458165,312.00988270252867,40.86725581541833,33.45011729747131
24,337.49,304.59274418428106,312.0098821323289,32.89725581571895,25.480117867671083
```

Εικόνα 1: Περιλαμβάνει τις πραγματικές τιμές και τις προβλέψεις των μοντέλων **Lasso** και **Ridge** στο **validation set** με χρήση πραγματικών εισόδων - **Μοντέλο Α**. Παρατηρείται ότι το

Lasso προσεγγίζει καλύτερα τις πραγματικές τιμές σε σύγκριση με το **Ridge**, επιβεβαιώνοντας τα χαμηλότερα σφάλματα **MAE** και **RMSE**.

Εικόνα 2: Η εξέλιξη του **MAE** ως προς τον χρονικό ορίζοντα δείχνει ότι και τα δύο μοντέλα ξεπερνούν το κατώφλι **MAE ≤ 10** από τον δεύτερο μήνα. Ο αξιόπιστος χρονικός ορίζοντας αποδεικνύεται **1 μήνας** για **Lasso** και **Ridge**.

Εικόνα 3: Παρουσιάζει τις αναδρομικές προβλέψεις - **Μοντέλο B** . Παρατηρείται συσσώρευση σφάλματος με την αύξηση του χρονικού ορίζοντα, με τις απόλυτες αποκλίσεις να αυξάνονται γρήγορα μετά τον πρώτο μήνα.

```
Feature,Ridge_Coefficient,Lasso_Coefficient
open,5.6892516194380125,-0.0
high,10.04363436216387,47.64210592752925
low,9.636792551729206,25.905971897594128
volume,-4.526612996323567,-0.0
close_t-1,5.750831049277387,-0.0
volume_t-1,-4.632205628330105,-0.0
close_t-2,5.254279218635809,-0.0
volume_t-2,-4.491836013861832,-0.0
close_t-3,6.040513660632336,0.0
volume_t-3,-4.90892700014337,-0.21047596266832422
open^2,-1.258526005185207,-12.382107943871725
open high,1.8208823453524376,-0.0
open low,1.9559831477418153,-0.0
open volume,-1.8824351145948959,-4.921146287124595
open close_t-1,-1.220889131718561,-0.0
open volume_t-1,-1.8878570550859917,-0.33202777266301453
open close_t-2,-1.698649807877788,-0.0
open volume_t-2,-1.4835241216380877,-0.0055273060822553675
open close_t-3,-0.8717630632983742,-0.0
open volume_t-3,-1.1474948921184205,-0.0
high^2,5.04611926558597,0.0
high low,5.017318033638776,0.0
high volume,3.9125419862739608,4.193090214879228
high close_t-1,1.865037301023677,-0.0
high volume_t-1,3.82705419677014,0.0
high close_t-2,1.4546881587421756,-0.0
high volume_t-2,3.4832619177537305,0.0
high close_t-3,2.31625963106096,0.0
```

Παράμετροι μοντέλων

Απόσπασμα από το αρχείο **B_coefficients.csv**.

Οι συντελεστές των μοντέλων εξάγονται σε κοινό αρχείο για σύγκριση. Το **Lasso** μηδενίζει μεγάλο αριθμό συντελεστών, ενώ το **Ridge** διατηρεί όλους τους συντελεστές με μικρότερες τιμές λόγω **L2** κανονικοποίησης.

5. ΕΡΩΤΗΜΑ Γ: ΜΕΙΩΣΗ ΔΙΑΣΤΑΣΗΣ

Συγκρίθηκαν τρεις διαφορετικές μέθοδοι μείωσης διάστασης/επιλογής χαρακτηριστικών:

1. PCA :Principal Component Analysis
2. CFA : Correlation-based Feature Analysis
3. RFE : Recursive Feature Elimination

Στόχος είναι να μειωθεί η πολυπλοκότητα του μοντέλου, να αποφευχθεί το **overfitting** και να βελτιωθεί η γενίκευση στο **validation set**.

Σε όλες τις μεθόδους χρησιμοποιήθηκε ίδιο μοντέλο πρόβλεψης: **Linear Regression**.

1. Principal Component Analysis - C_PCA.py

Η **Principal Component Analysis** είναι μέθοδος μείωσης διάστασης που βασίζεται σε γραμμικό μετασχηματισμό των αρχικών χαρακτηριστικών σε νέο σύνολο ορθογώνιων μεταβλητών, ονομαζόμενων κύριες συνιστώσες, οι οποίες μεγιστοποιούν τη διακύμανση των δεδομένων.

Στην παρούσα υλοποίηση εφαρμόστηκε κανονικοποίηση μέσω **StandardScaler**, καθώς η **PCA** είναι ευαίσθητη στην κλίμακα των χαρακτηριστικών. Ο αριθμός των τελικών συνιστωσών επιλέχθηκε δυναμικά ώστε να διατηρείται τουλάχιστον το **95%** της συνολικής διακύμανσης, βάσει του αθροιστικού λόγου εξηγούμενης διακύμανσης. Οι τελικές συνιστώσες χρησιμοποιήθηκαν ως είσοδος σε γραμμικό μοντέλο παλινδρόμησης, το οποίο αξιολογήθηκε μέσω **MAE** και **RMSE** στο **validation set**, επιτρέποντας τη συγκριτική αξιολόγηση της **PCA** με τις υπόλοιπες μεθόδους.

Αξιολόγηση

PCA RESULTS

TRAIN METRICS

MAE : 3.4863

RMSE: 4.8972

VALIDATION METRICS

MAE : 8.4762

RMSE: 10.4725

Παρατηρείται χαμηλό σφάλμα στο σύνολο εκπαίδευσης, αλλά υψηλότερο σφάλμα στο σύνολο επικύρωσης, γεγονός που υποδηλώνει ότι το μοντέλο δεν γενικεύει επαρκώς σε νέα δεδομένα. Το αποτέλεσμα δείχνει ότι η PCA διατηρεί τη γενική πληροφορία, αλλά δεν αποτύπωσε επαρκώς τη χρονική εξάρτηση της χρονοσειράς.

PCA COMPONENTS INFO

Number of components: 3

Explained variance ratio per component:

PC1: 0.8482

PC2: 0.0927

PC3: 0.0246

Cumulative explained variance: 0.9655

Εδώ εμφανίζεται το ποσοστό διακύμανσης που εξηγεί κάθε κύρια συνιστώσα. Η πρώτη συνιστώσα PC1 καλύπτει το μεγαλύτερο ποσοστό της πληροφορίας, ενώ οι υπόλοιπες συνεισφέρουν μικρότερα ποσά. Συνολικά, διατηρείται το μεγαλύτερο μέρος της πληροφορίας (96.55%) με μόλις τρεις συνιστώσες, γεγονός που καταδεικνύει την ισχυρή συμπίεση δεδομένων.

PCA COMPONENT MATRIX (Eigenvectors):

	open	high	low	volume	close_t-1	volume_t-1	close_t-2	volume_t-2	close_t-3	volume_t-3
PC1	0.334	0.333	0.334	-0.286	0.334	-0.289	0.334	-0.289	0.332	-0.288
PC2	0.234	0.239	0.223	0.403	0.234	0.427	0.239	0.420	0.242	0.383
PC3	0.010	-0.004	0.040	-0.609	0.004	-0.342	-0.008	0.353	-0.018	0.621

Παραπάνω απεικονίζεται ο πίνακας βαρύτητας των αρχικών χαρακτηριστικών στις κύριες συνιστώσες. Η πρώτη συνιστώσα συνδυάζει σχεδόν εξίσου όλα τα χαρακτηριστικά τιμών και καθυστερημένων τιμών, υποδεικνύοντας γενική τάση αγοράς. Οι επόμενες συνιστώσες σχετίζονται περισσότερο με τη μεταβλητότητα του όγκου συναλλαγών.

2. Correlation-based Feature Analysis – C_CFA.py

Η **Correlation-based Feature Analysis** (CFA) είναι τεχνική επιλογής χαρακτηριστικών που βασίζεται στη μέτρηση της γραμμικής συσχέτισης Pearson μεταξύ κάθε μεταβλητής εισόδου και της μεταβλητής στόχου.

Στην παρούσα υλοποίηση, ο πίνακας συσχέτισης υπολογίστηκε αποκλειστικά στο **training set** ώστε να αποφευχθεί το **data leakage**. Στη συνέχεια εφαρμόστηκε φίλτρο επιλογής με βάση την απόλυτη τιμή του συντελεστή συσχέτισης, με προκαθορισμένο κατώφλι $|p| \geq 0.3$. Τα χαρακτηριστικά που ικανοποιούσαν το κριτήριο χρησιμοποιήθηκαν ως είσοδος σε γραμμικό μοντέλο παλινδρόμησης, το οποίο εκπαιδεύτηκε και αξιολογήθηκε μέσω των μετρικών **MAE** και **RMSE** στο **validation set**, επιτρέποντας την αντικειμενική σύγκριση με άλλες μεθόδους μείωσης διάστασης.

Αξιολόγηση

```
TRAIN SET
MAE : 1.1578
RMSE: 1.6484
```

```
VALIDATION SET
MAE : 2.6542
RMSE: 3.4401
```

Το χαμηλό σφάλμα στο **training set** και η μικρή απόκλιση από το **validation set** υποδεικνύουν πολύ καλή γενίκευση και απουσία **overfitting**. Η **CFA** παρουσιάζει τη μικρότερη απόδοση σφάλματος σε σύγκριση με άλλες μεθόδους.

```
close      1.000000
close_t-1  0.998213
high       0.997669
low        0.997175
open       0.995203
close_t-2  0.994140
close_t-3  0.989910
volume_t-3 -0.733627
volume_t-2 -0.731829
volume_t-1 -0.729886
volume     -0.727359
```

Το τελικό σύνολο χαρακτηριστικών που επιλέχθηκε με βάση κατώφλι συσχέτισης $|\text{corr}| \geq 0.3$. Επιλέχθηκαν συνολικά **10** χαρακτηριστικά, τα οποία περιλαμβάνουν καθυστερημένες τιμές close, τιμές αγοράς και μεταβλητές όγκου, γεγονός που δείχνει ότι το μοντέλο διατηρεί τόσο χρονική όσο και χρηματοοικονομική πληροφορία.

```
CFA MODEL COEFFICIENTS (scaled)
Feature    Coefficient
close_t-1  2.746712e+00
close_t-2 -1.710502e+00
close_t-3  5.126273e-01
open      -4.626442e-01
high      -4.814081e-02
low       -3.748803e-02
volume    -1.930024e-09
volume_t-1 -1.587841e-09
volume_t-2 -2.658073e-10
volume_t-3  1.923492e-10
```

Οι **συντελεστές του γραμμικού μοντέλου** που προέκυψε από την **CFA**. Διαπιστώνεται ότι οι καθυστερημένες τιμές του **close** έχουν τους υψηλότερους συντελεστές, γεγονός που δείχνει την ισχυρή επίδρασή τους στην πρόβλεψη, ενώ οι μεταβλητές όγκου εμφανίζουν μικρότερη συνεισφορά.

3. Recursive Feature Elimination – C_RFE_Wrapper.py

Η **Recursive Feature Elimination** είναι μέθοδος επιλογής χαρακτηριστικών τύπου **wrapper**, η οποία βασίζεται στην επαναληπτική εκπαίδευση ενός μοντέλου πρόβλεψης και στην αξιολόγηση της σχετικής σημασίας των χαρακτηριστικών του.

Στην παρούσα υλοποίηση χρησιμοποιήθηκε ως **εκτιμητής γραμμικό μοντέλο παλινδρόμησης**, το οποίο επανεκπαιδεύεται σε κάθε επανάληψη αφαιρώντας το λιγότερο σημαντικό χαρακτηριστικό σύμφωνα με τους συντελεστές του μοντέλου. Η διαδικασία συνεχίζεται μέχρι να παραμείνουν **4** χαρακτηριστικά. Το τελικό σύνολο χαρακτηριστικών χρησιμοποιήθηκε για την εκπαίδευση νέου γραμμικού μοντέλου, το οποίο αξιολογήθηκε μέσω **MAE** και **RMSE** στο **validation set**, επιτρέποντας άμεση σύγκριση με **PCA** και **CFA**.

Αξιολόγηση

RFE MODEL RESULTS

TRAIN SET

MAE : 1.1672

RMSE: 1.6754

VALIDATION SET

MAE : 2.8537

RMSE: 3.625

Παρατηρείται σημαντικά χαμηλό σφάλμα εκπαίδευσης και μικρή απόκλιση στο **validation set**, γεγονός που καταδεικνύει ικανοποιητική γενίκευση και όχι overfitting. Το **RFE** παρουσιάζει επίδοση παρόμοια με την **CFA**, με σαφώς καλύτερα αποτελέσματα από την **PCA**.

RFE SELECTED FEATURES:

1. open
2. close_t-1
3. close_t-2
4. close_t-3

Feature ranking (1 = selected):

Feature	Rank
open	1
close_t-1	1
close_t-2	1
close_t-3	1
high	2
low	3
volume	4
volume_t-1	5
volume_t-2	6
volume_t-3	7

Το σύνολο των **4** χαρακτηριστικών που επιλέχθηκαν από τη μέθοδο **RFE**, καθώς και η κατάταξη όλων των υπολοίπων χαρακτηριστικών βάσει της σημασίας τους. Οι μεταβλητές **open**, **close_t-1**, **close_t-2** και **close_t-3** διατηρήθηκαν στο τελικό μοντέλο, ενώ τα χαρακτηριστικά που σχετίζονται με τον όγκο βρίσκονται στις τελευταίες θέσεις, έχοντας μικρότερη συνεισφορά στην πρόβλεψη της τιμής.

RFE MODEL COEFFICIENTS

Feature	Coefficient
close_t-1	2.591368
close_t-2	-1.605404
close_t-3	0.481283
open	-0.464598

Οι συντελεστές του τελικού γραμμικού μοντέλου που προέκυψε μετά την εφαρμογή του **RFE**. Η μεταβλητή **close_t-1** έχει τον μεγαλύτερο θετικό συντελεστή, επιβεβαιώνοντας τη σημασία της πιο πρόσφατης τιμής στην πρόβλεψη της επόμενης. Αντίθετα, οι **close_t-2** και **open** παρουσιάζουν αρνητική επίδραση, οπότε έχουν διορθωτικό ρόλο στη μοντελοποίηση της χρονικής εξέλιξης.

Σύγκριση αποτελεσμάτων

Η συγκριτική αξιολόγηση των τριών μεθόδων δείχνει ότι η καλύτερη μέθοδος είναι η **CFA** ως προς την ακρίβεια πρόβλεψης, καθώς παρουσίασε το μικρότερο σφάλμα στο **validation set**. Η **RFE** είναι πάρα πολύ κοντά σε απόδοση, διατηρεί σημαντικά λιγότερα χαρακτηριστικά και επιτυγχάνει παρόμοιο επίπεδο γενίκευσης. Αντίθετα, η **PCA**, παρότι πέτυχε μεγάλη μείωση της διάστασης, εμφάνισε σημαντικά υψηλότερο σφάλμα, γεγονός που καταδεικνύει ότι η γραμμική αναπαράσταση μέσω κύριων συνιστωσών δεν αποτύπωσε αποτελεσματικά την χρονοσειρά. Επομένως, επιλέγεται η **CFA** ως βέλτιστη προσέγγιση, με τη **RFE** να αποτελεί αξιόπιστη εναλλακτική.

6. ΕΡΩΤΗΜΑ Δ: ΠΡΟΒΛΕΨΗ ΤΙΜΗΣ - D_meCFA.py

Πρόβλεψη Τιμών Μετοχής για Δεκέμβριο 2025 και Ιανουάριο 2026

Για την πρόβλεψη μελλοντικών τιμών επιλέχθηκε ως τελικό μοντέλο το **CFA** σε συνδυασμό με **γραμμική παλινδρόμηση**, καθώς παρουσίασε την καλύτερη απόδοση στο **validation set** στο Ερώτημα Γ.

Η πρόβλεψη πραγματοποιήθηκε με τη μέθοδο της **αναδρομικής πρόβλεψης**, όπου η εκτιμώμενη τιμή ενός μήνα χρησιμοποιείται ως είσοδος για την πρόβλεψη του επόμενου.

Το μοντέλο εκπαιδεύτηκε χρησιμοποιώντας όλα τα διαθέσιμα ιστορικά δεδομένα **έως το 2025**. Τα χαρακτηριστικά εισόδου που χρησιμοποιήθηκαν προέκυψαν από τη **διαδικασία CFA** και περιλαμβάνουν: **close_t-1, close_t-2, close_t-3, volume, volume_t-1, volume_t-2, volume_t-3, open, high, low**

```
RESULTS
December 2025 : 337.37
January 2026  : 334.71
```

Το μοντέλο **CFA** προβλέπει ήπια ανοδική τάση της τιμής της μετοχής από τον **Δεκέμβριο 2025** προς τον **Ιανουάριο 2026**. Η μικρή μεταβολή μεταξύ των δύο μηνών υποδηλώνει σταθεροποίηση της τιμής σε υψηλά επίπεδα.

Δεδομένης της αναδρομικής φύσης της πρόβλεψης, η εκτίμηση του πρώτου μήνα θεωρείται πιο αξιόπιστη.